

République Islamique de Mauritanie

Honneur – Fraternité – justice



Département de Math – Info
FST

Rapport du projet ML :

CLASSIFICATION DE QUALITE DU POISSON

Réalisé par :

Ahmed Bechir WEDHAN (C-34639)

Sous la supervision de :

Professeur Ezyn SEGNANE



Table des matières

Introduction	1
Objectifs :	1
Présentation du dataset :.....	2
Qualité des données :	2
1. METHODOLOGIE	3
1.1. Chargement et Exploration des Données	3
1.2. Analyse Exploratoire des Données (EDA).....	3
1.3. Prétraitement des Données :	4
1.4. Division des Données	5
1.5. Modèles de Classification Testés	5
1.6. Évaluation des Performances	7
1.7. Sauvegarde du Modèle	7
1.8. Déploiement de l'Application	7
2. RESULTATS.....	9
2.1. Analyse exploratoire des données	9
2.1.1. Distribution des espèces	9
2.1.2. Histogrammes des variables numériques.....	9
2.1.3. Boxplots des variables numériques par espèce.....	10
2.1.4. Matrice de corrélation des variables explicatives.....	11
2.2. Prétraitement des données	12
2.2.1. Détection et traitement des outliers	13
2.2.2. Encodage de la variable cible	13
2.2.3. Séparation des données	14
2.3. Modélisation et Optimisation	14
2.3.1. Optimisation du modèle k-NN	15
2.3.2. Analyse de l'Arbre de Décision	16
2.3.3. Importance des Variables avec Random Forest.....	16
2.4. Résultats expérimentaux	18
2.4.1. Comparaison des modèles	18
2.4.2. Choix du modèle final	19
3. DISCUSSION ET ANALYSE CRITIQUE	20
3.1. Analyse comparative des performances	20
3.2. Le cas particulier du k-NN avec k = 1	21
3.3. Importance des variables : le rôle central de Height.....	21

3.4. Lecture des matrices de confusion	21
3.5. Limites du travail réalisé	22
3.6. Synthèse de l'analyse critique	22
CONCLUSION ET PERSPECTIVES	24
Bibliographie.....	26
Datasets	26
Ouvrages	26
Documentation technique	26

Liste des figures

Figure 1: Distribution des espèces	9
Figure 2: Histogrammes des variables numériques.....	10
Figure 3 : Boxplots des variables numériques par espèce.....	11
Figure 4: Matrice de corrélation des variables explicatives.	12
Figure 5: Courbe de validation croisée du k-NN selon le nombre de voisins.....	15
Figure 6: Visualisation de l'arbre de décision limité à une profondeur d'affichage de 3	16
Figure 7: Importance des variables selon Random Forest.	17
Figure 8: Comparaison graphique des métriques des modèles	18
Figure 9: Matrices de confusion des quatre modèles.	19

INTRODUCTION

L'identification des espèces de poissons est une tâche importante dans l'aquaculture, la biologie marine, le contrôle qualité et la gestion durable des ressources halieutiques. Dans un contexte réel, cette identification peut être réalisée manuellement par des spécialistes à partir de critères anatomiques. Toutefois, cette méthode peut devenir lente, coûteuse et dépendante de l'expérience de l'observateur.

Le Machine Learning permet d'automatiser cette tâche en apprenant des relations entre les mesures physiques d'un poisson et son espèce. Dans ce projet, les entrées du modèle sont exclusivement numériques, ce qui rend l'approche rapide, simple à déployer et compatible avec une interface web légère.

Le projet vise donc à concevoir un modèle fiable, interprétable et exploitable dans une application Streamlit permettant à un utilisateur de saisir les caractéristiques d'un poisson et d'obtenir automatiquement l'espèce prédite.

Objectifs :

L'objectif principal est de construire un modèle capable de prédire l'espèce d'un poisson à partir de ses caractéristiques morphologiques (poids, longueurs, hauteur, largeur), et de comparer les performances de plusieurs algorithmes de classification supervisée.

Pour atteindre cet objectif, les étapes suivantes ont été réalisées :

- Analyser la structure et les caractéristiques du dataset « Fish Market »
- Préparer et prétraiter les variables explicatives ainsi que la variable cible
- Mettre en œuvre et comparer plusieurs algorithmes de classification supervisée
- Évaluer les performances des modèles à l'aide de métriques adaptées telles que l'Accuracy, la Precision, le Recall et le F1-Score
- Sélectionner le modèle offrant les meilleures performances
- Sauvegarder les objets nécessaires au déploiement de l'application, notamment le modèle entraîné, le scaler de normalisation et l'encodeur des classes.

Présentation du dataset :

Le dataset utilisé est Fish Market. Il contient 159 observations et 7 colonnes. Chaque ligne représente un poisson, décrit par son espèce et six mesures numériques. La variable cible est Species, tandis que les autres colonnes constituent les variables explicatives.

Variable	Type	Rôle	Description
Species	Catégorielle	Cible	Espèce du poisson
Weight	Numérique	Feature	Poids du poisson
Length1	Numérique	Feature	Longueur verticale
Length2	Numérique	Feature	Longueur diagonale
Length3	Numérique	Feature	Longueur croisée
Height	Numérique	Feature	Hauteur
Width	Numérique	Feature	Largeur

Voici le nombre d'observation de chaque espèce :

Espèce	Nombre d'observations
Perch	56
Bream	35
Roach	20
Pike	17
Smelt	14
Parkki	11
Whitefish	6

Qualité des données :

L'inspection du dataset montre qu'aucune valeur manquante n'est présente dans les données. Cette qualité initiale constitue un avantage important puisqu'elle permet de construire le pipeline de Machine Learning sans recourir à des techniques d'imputation ou de nettoyage supplémentaires.

De plus, aucune incohérence majeure n'a été détectée dans les variables observées, ce qui garantit une base fiable pour l'apprentissage des modèles.

1. METHODOLOGIE

La méthodologie adoptée dans ce projet repose sur un pipeline complet de Machine Learning visant à construire un modèle capable de classifier automatiquement les espèces de poissons à partir de leurs caractéristiques morphologiques. Cette approche comprend plusieurs étapes allant de l'exploration des données jusqu'au déploiement du modèle.

1.1. Chargement et Exploration des Données

La première étape a consisté à charger le dataset « Fish Market » et à examiner sa structure générale.

Cette analyse préliminaire avait pour objectifs :

- Identifier les variables disponibles
- Vérifier le nombre d'observations et de caractéristiques
- Détecter d'éventuelles valeurs manquantes
- Comprendre la nature des variables (numériques ou catégorielles)
- Étudier la répartition des espèces de poissons.

L'exploration a montré que le dataset contient 159 observations réparties sur 7 variables, dont une variable cible (Species) et six variables numériques décrivant les caractéristiques physiques des poissons.

Aucune valeur manquante n'a été détectée, ce qui a permis de poursuivre l'analyse sans étape d'imputation.

1.2. Analyse Exploratoire des Données (EDA)

Une analyse exploratoire approfondie a ensuite été réalisée afin de mieux comprendre les relations existantes entre les variables.

Plusieurs visualisations ont été produites :

Distribution des variables numériques

Des histogrammes ont été utilisés pour analyser la distribution des variables :

- Weight
- Length1
- Length2
- Length3

- Height
- Width

Cette analyse a révélé une asymétrie positive pour plusieurs variables, notamment le poids et les longueurs, indiquant la présence de poissons de tailles très différentes.

Répartition des espèces

Un graphique en barres a permis d'étudier la distribution des différentes espèces présentes dans le dataset.

Les résultats montrent que certaines espèces, comme Perch et Bream, sont plus représentées que d'autres, ce qui peut influencer l'apprentissage des modèles.

Analyse des corrélations

Une matrice de corrélation a été calculée afin d'identifier les relations entre les variables numériques.

Les résultats ont mis en évidence une forte corrélation entre les différentes mesures de longueur ainsi qu'entre le poids et les dimensions du poisson. Ces relations suggèrent que ces variables jouent un rôle important dans la détermination de l'espèce.

1.3. Prétraitement des Données :

Séparation des variables

Les données ont été divisées en :

Variables explicatives (X) :

- Weight
- Length1
- Length2
- Length3
- Height
- Width

Variable cible (y) :

Species

Encodage de la variable cible

La variable Species étant de nature catégorielle, elle a été transformée en valeurs numériques à l'aide de la méthode LabelEncoder.

Cette transformation est indispensable car les algorithmes de Machine Learning nécessitent des données numériques pour effectuer leurs calculs.

Normalisation des données

Les variables numériques présentent des échelles très différentes. Par exemple, le poids peut atteindre plusieurs centaines de grammes alors que la largeur varie sur une plage beaucoup plus réduite.

Afin d'éviter qu'une variable domine les autres lors de l'apprentissage, une standardisation a été appliquée à l'aide de StandardScaler.

Cette méthode transforme chaque variable selon la formule suivante :

- Moyenne = 0
- Écart-type = 1

La normalisation est particulièrement importante pour les modèles sensibles à l'échelle des données tels que KNN et SVM.

1.4. Division des Données

Le dataset a été séparé en deux ensembles :

- Ensemble d'entraînement : 80 %
- Ensemble de test : 20 %

L'ensemble d'entraînement est utilisé pour apprendre les paramètres du modèle, tandis que l'ensemble de test permet d'évaluer sa capacité de généralisation sur des données jamais vues auparavant.

Cette séparation permet d'obtenir une estimation réaliste des performances du modèle.

1.5. Modèles de Classification Testés

Afin d'identifier l'algorithme le plus performant, plusieurs modèles de classification supervisée ont été entraînés et comparés.

Régression Logistique

La régression logistique est un modèle linéaire largement utilisé pour les problèmes de classification.

Caractéristiques :

- Rapide à entraîner ;
- Facile à interpréter ;
- Constitue un excellent modèle de référence.

K-Nearest Neighbors (KNN)

Le principe de KNN consiste à attribuer à une observation la classe majoritaire parmi ses k plus proches voisins.

Avantages :

- Simplicité ;
- Bonne performance sur les petits datasets.

Limites :

- Sensibilité à la normalisation ;
- Temps de prédiction plus élevé.

Support Vector Machine (SVM)

Le SVM cherche à construire une frontière de décision optimale maximisant la séparation entre les différentes classes.

Avantages :

- Excellente capacité de généralisation ;
- Très performant sur des datasets de taille moyenne ;
- Bonne gestion des données complexes.

Random Forest

Random Forest est un algorithme d'ensemble basé sur la combinaison de plusieurs arbres de décision.

Avantages :

- Réduction du surapprentissage ;

- Robustesse face au bruit ;
- Bonne capacité à capturer les relations non linéaires.

1.6. Évaluation des Performances

Les modèles ont été évalués à l'aide de plusieurs métriques afin d'obtenir une analyse complète de leurs performances.

métriques	Description
Accuracy	Mesure la proportion de prédictions correctes réalisées par le modèle.
Precision	Indique la proportion des prédictions positives qui sont effectivement correctes
Recall	Mesure la capacité du modèle à identifier correctement les observations appartenant à une classe donnée.
F1-Score	Représente la moyenne harmonique entre la Precision et le Recall. Cette métrique est particulièrement utile lorsque les classes sont déséquilibrées.
Matrice de confusion	Permet de visualiser les erreurs de classification et d'identifier les espèces les plus difficiles à distinguer.

1.7. Sauvegarde du Modèle

Une fois le meilleur modèle sélectionné, les objets nécessaires au déploiement ont été sauvegardés à l'aide de la bibliothèque Joblib :

- `best_model.pkl` : modèle final entraîné ;
- `scaler.pkl` : objet de normalisation ;
- `label_encoder.pkl` : encodeur des classes

Cette étape garantit la reproductibilité des résultats et facilite l'intégration du modèle dans l'application web

1.8. Déploiement de l'Application

La dernière étape du projet a consisté à développer une interface utilisateur avec Streamlit.

L'application permet :

- De saisir les caractéristiques morphologiques d'un poisson ;
- D'effectuer automatiquement le prétraitement des données ;
- D'obtenir la prédiction de l'espèce ;
- D'afficher les probabilités associées à chaque classe.

Cette interface rend le modèle accessible aux utilisateurs non spécialisés et constitue une première étape vers une mise en production opérationnelle.

2. RESULTATS

2.1. Analyse exploratoire des données

L'analyse exploratoire vise à comprendre la distribution des classes, la forme des variables numériques, les relations entre variables et l'existence de valeurs atypiques. Elle permet aussi d'orienter les choix de prétraitement et de modèles.

2.1.1. Distribution des espèces




Figure 1: Distribution des espèces

Interprétation :

La figure montre que l'espèce Perch est la plus représentée dans le dataset avec 35,2 % des observations, tandis que Whitefish est la moins représentée avec seulement 3,8 %. Cette répartition indique un léger déséquilibre entre les classes, ce qui peut influencer les performances des modèles de classification en favorisant les espèces les plus fréquentes.

2.1.2. Histogrammes des variables numériques

Histogrammes des variables numériques




Figure 2: Histogrammes des variables numériques

Interprétation :

Les histogrammes montrent que la plupart des variables numériques présentent une **asymétrie positive (skewness à droite)**, particulièrement pour **Weight, Length1, Length2 et Length3**. Cela est visible par le fait que la moyenne (ligne rouge) est généralement supérieure à la médiane (ligne orange). Cette distribution indique la présence de quelques poissons de grande taille qui augmentent la moyenne. Ces différences d'échelle et de distribution justifient l'application d'une **normalisation (StandardScaler)** avant l'entraînement des modèles de classification afin d'améliorer leurs performances et leur stabilité.

2.1.3. Boxplots des variables numériques par espèce




Figure 3 : Boxplots des variables numériques par espèce.

Interprétation :

Les boxplots montrent des différences significatives entre les espèces pour l'ensemble des caractéristiques morphologiques. Les espèces **Pike**, **Bream** et **Whitefish** présentent généralement des valeurs plus élevées de poids et de dimensions, tandis que **Smelt** possède les plus petites mesures. On observe également une variabilité importante pour certaines espèces, notamment **Perch** et **Pike**, comme l'indiquent l'étendue des boîtes et des moustaches. La présence de quelques valeurs atypiques (outliers) est également visible. Ces différences morphologiques entre les espèces constituent des caractéristiques discriminantes qui facilitent leur classification par les algorithmes de Machine Learning.

2.1.4. Matrice de corrélation des variables explicatives.




Figure 4: Matrice de corrélation des variables explicatives.

Interprétation :

La matrice de corrélation indique une corrélation très forte entre Length1, Length2 et Length3, supérieure à 0,99. Cette multi colinéarité est logique car ces variables mesurent des dimensions proches du même individu. Elle peut réduire l'apport marginal de certaines variables, mais elle n'empêche pas les modèles non linéaires ou à marge maximale de fonctionner efficacement.

2.2. Prétraitement des données

Le prétraitement des données constitue une étape essentielle du projet, car il permet de garantir la qualité, la cohérence et la pertinence des informations utilisées lors de l'apprentissage des modèles de Machine Learning. Cette phase comprend la détection des valeurs atypiques, l'encodage de la variable cible, la séparation des données ainsi que la standardisation des variables numériques.

2.2.1. Détection et traitement des outliers

Les valeurs atypiques (outliers) ont été identifiées à l'aide de la méthode de l'intervalle interquartile (IQR). Cette approche permet de déterminer les bornes inférieure et supérieure au-delà desquelles une observation est considérée comme atypique.

Variable	Outliers détectés	Borne inférieure	Borne supérieure	Décision
Weight	3	-675,00	1445,00	Conservés
Length1	3	-1,43	53,18	Conservés
Length2	3	-0,75	57,25	Conservés
Length3	1	-1,60	64,40	Conservés
Height	0	-3,69	22,00	Conservés
Width	0	0,09	8,88	Conservés

L'analyse a révélé la présence d'un nombre limité de valeurs atypiques dans certaines variables, principalement le poids et les différentes mesures de longueur. Toutefois, ces observations ont été conservées car elles correspondent vraisemblablement à de véritables poissons de grande taille et non à des erreurs de saisie ou de mesure. Leur suppression aurait réduit la diversité du dataset et risqué d'altérer la capacité du modèle à généraliser sur des individus présentant des caractéristiques extrêmes.

2.2.2. Encodage de la variable cible

La variable **Species** étant de nature catégorielle, elle a été transformée en valeurs numériques à l'aide de la méthode **LabelEncoder** de la bibliothèque **Scikit-learn**. Cette étape est indispensable puisque les algorithmes de Machine Learning ne peuvent pas traiter directement des données textuelles.

Le tableau suivant présente la correspondance entre les espèces et leurs codes numériques :

Espèce	Encodage
Bream	0
Parkki	1
Perch	2
Pike	3
Roach	4
Smelt	5
Whitefish	6

Cet encodage permet de représenter chaque espèce par une valeur numérique unique tout en conservant l'intégralité des informations nécessaires à l'apprentissage.

2.2.3. Séparation des données

Afin d'évaluer objectivement les performances des modèles, le dataset a été divisé en deux ensembles distincts :

Échantillon	Nombre	Pourcentage
Train	127	80 %
Test	32	20 %

La séparation a été réalisée selon une stratégie stratifiée, garantissant une répartition similaire des différentes espèces dans les ensembles d'entraînement et de test. Cette approche est particulièrement importante dans le cadre d'un problème de classification multiclassés comportant des espèces faiblement représentées, car elle permet d'obtenir une évaluation plus fiable et plus représentative des performances du modèle.

2.3. Modélisation et Optimisation

Quatre algorithmes ont été entraînés et optimisés. Le choix de ces modèles permet de comparer des approches basées sur la distance, les arbres, les ensembles et les marges de séparation.

Les combinaisons de paramètres testées ainsi que les meilleurs paramètres obtenus pour chaque modèle sont présentés dans le tableau suivant :

Modèle	Hyperparamètres testés	Meilleurs paramètres
k-NN	n_neighbors = 1 à 15 ; metric = euclidean, manhattan	metric = euclidean ; n_neighbors = 1
Arbre de décision	max_depth ; min_samples_split ; criterion	criterion = gini ; max_depth = 10 ; min_samples_split = 5

Random Forest	n_estimators ; max_depth ; min_samples_split	n_estimators = 100 ; max_depth = None ; min_samples_split = 2
SVM	C ; kernel ; gamma	C = 100 ; kernel = linear ; gamma = scale

Les résultats obtenus montrent que chaque algorithme nécessite un réglage spécifique afin d'atteindre son niveau de performance optimal.

2.3.1. Optimisation du modèle k-NN




Figure 5: Courbe de validation croisée du k-NN selon le nombre de voisins.

L'analyse de la courbe de validation croisée montre que la meilleure performance est obtenue pour $k = 1$ avec la distance euclidienne. Ce résultat indique que les observations appartenant à une même espèce sont relativement proches les unes des autres dans l'espace des caractéristiques après standardisation.

2.3.2. Analyse de l'Arbre de Décision




Figure 6: Visualisation de l'arbre de décision limité à une profondeur d'affichage de 3

L'arbre de décision fournit une représentation visuelle claire du processus de classification. Chaque nœud correspond à une règle de décision basée sur une caractéristique morphologique, permettant de distinguer progressivement les différentes espèces.

Afin de limiter le risque de surapprentissage (overfitting), plusieurs contraintes ont été appliquées, notamment :

- Une profondeur maximale (max_depth) de 10 ;
- Un minimum de 5 observations pour effectuer une division (min_samples_split = 5).

Ces paramètres permettent d'obtenir un modèle plus robuste tout en conservant une bonne capacité d'interprétation.

2.3.3. Importance des Variables avec Random Forest




Figure 7: Importance des variables selon Random Forest.

L'algorithme Random Forest permet d'estimer l'importance relative de chaque variable dans le processus de classification.

Les résultats montrent que Height est la variable la plus influente avec une importance de 0,3327. Elle est suivie par Length3, Width, Length1, Length2 et enfin Weight.

Cette hiérarchie indique que les dimensions corporelles du poisson jouent un rôle plus important que son poids seul dans la distinction des espèces. En particulier, la hauteur et les mesures de longueur semblent contenir des informations discriminantes essentielles permettant aux modèles de différencier efficacement les différentes catégories de poissons.

2.4. Résultats expérimentaux

2.4.1. Comparaison des modèles

Le tableau suivant présente les performances obtenues par les différents algorithmes de classification sur l'ensemble de test ainsi que les résultats moyens obtenus lors de la validation croisée. Les métriques utilisées permettent d'évaluer à la fois la capacité de généralisation des modèles et leur qualité de prédiction sur des données non observées pendant l'apprentissage.

Modèle	CV Accuracy	CV Std	Accuracy	Precision	Recall	F1-score
SVM	0,9292	0,0154	0,9688	0,9437	0,9688	0,9549
Arbre de décision	0,7560	0,0131	0,8125	0,8078	0,8125	0,8058
k-NN	0,8182	0,0748	0,8125	0,8016	0,8125	0,8041
Random Forest	0,7640	0,0222	0,8125	0,7891	0,8125	0,7991




Figure 8: Comparaison graphique des métriques des modèles

Le SVM domine nettement les autres modèles avec une accuracy de 96,88 % et un F1-score de 95,49 %. Les trois autres modèles obtiennent une accuracy identique de 81,25 %, mais avec des différences légères sur la précision et le F1-score.

Matrice de confusion :

Matrices de confusion — tous les modèles




Figure 9: Matrices de confusion des quatre modèles.

Les matrices de confusion montrent que le modèle SVM est le plus performant, avec une classification correcte de presque toutes les observations. La seule erreur concerne l'espèce Whitefish, qui est peu représentée dans le dataset. Les modèles k-NN, Random Forest et Arbre de décision commettent davantage de confusions, notamment entre les espèces Perch, Roach et Smelt. Ces résultats confirment que le SVM est le modèle le plus précis et le mieux adapté à ce problème de classification.

2.4.2. Choix du modèle final

Le modèle final retenu est SVM avec kernel linéaire, $C = 100$ et $\gamma = \text{scale}$. Il est sauvegardé dans `best_model.pkl`. Les objets `scaler.pkl` et `label_encoder.pkl` sont également nécessaires pour garantir une prédiction cohérente en production.

3. DISCUSSION ET ANALYSE CRITIQUE

Cette section propose une analyse critique des résultats obtenus, en mettant en perspective les performances des différents modèles, les facteurs explicatifs de ces performances, ainsi que les limites du travail réalisé. L'objectif est de dépasser la simple lecture des scores pour comprendre pourquoi certains modèles se comportent mieux que d'autres sur ce jeu de données, et quelles précautions doivent accompagner l'interprétation de ces résultats.

3.1. Analyse comparative des performances

Les résultats obtenus mettent en évidence un écart de performance très net entre le SVM et les trois autres modèles. Avec une accuracy de 96,88 % et un F1-score de 95,49 %, le SVM se distingue nettement de l'Arbre de décision, du k-NN et du Random Forest, qui obtiennent tous une accuracy identique de 81,25 % sur le jeu de test. Ce résultat mérite d'être interprété avec attention, car une telle convergence entre trois algorithmes de nature très différente (un modèle géométrique de distances, un modèle hiérarchique de règles et un ensemble d'arbres) suggère que ces modèles atteignent un plafond commun imposé par la structure même des données, plutôt qu'une coïncidence.

Le SVM avec noyau linéaire ($C = 100$, $\gamma = \text{scale}$) bénéficie pleinement de la normalisation Z-score appliquée en amont : dans un espace où toutes les variables contribuent à égalité, la recherche de l'hyperplan séparateur de marge maximale devient particulièrement efficace, surtout lorsque les classes sont, comme c'est probablement le cas ici, linéairement séparables ou quasi-séparables après standardisation. Le choix d'un noyau linéaire plutôt que RBF est lui-même informatif : il indique que les frontières entre espèces ne nécessitent pas de transformation non linéaire complexe, ce qui est cohérent avec la forte corrélation observée entre les variables de longueur — ces dernières se comportent presque comme une combinaison linéaire les unes des autres.

À l'inverse, la validation croisée révèle un écart important entre les scores CV et les scores de test pour le k-NN (CV Accuracy = 0,8182 avec un écart-type élevé de 0,0748) et pour l'Arbre de décision et le Random Forest (CV Accuracy autour de 0,75-0,76, inférieure à leur accuracy de test de 0,8125). Cette instabilité, en particulier l'écart-type élevé du k-NN, traduit une forte sensibilité de ces modèles au découpage des données utilisé lors de la validation croisée — un phénomène attendu sur un dataset de taille réduite (127 individus en entraînement) où certaines espèces, comme Whitefish (6 individus) ou Parkki (11 individus), ne sont représentées que par une poignée d'observations dans chaque fold.

3.2. Le cas particulier du k-NN avec $k = 1$

Le résultat selon lequel $k = 1$ constitue la meilleure configuration pour le k-NN appelle une lecture nuancée. D'une part, il confirme que les individus d'une même espèce occupent des régions compactes et bien délimitées dans l'espace standardisé des six variables, ce qui est encourageant quant à la séparabilité du problème. D'autre part, un k aussi faible rend le modèle extrêmement sensible au bruit et aux valeurs atypiques : chaque prédiction dépend d'un seul voisin, sans aucun effet de lissage. Ce choix, bien qu'optimal sur la validation croisée réalisée, comporte donc un risque de surapprentissage local que l'écart-type élevé observé (0,0748) tend à confirmer. Un k légèrement supérieur (par exemple $k = 3$ ou $k = 5$) aurait pu constituer un compromis plus robuste, même au prix d'un score de validation croisée légèrement inférieur.

3.3. Importance des variables : le rôle central de Height

L'analyse de l'importance des variables via Random Forest apporte un éclairage important sur la nature du problème. Contrairement à une intuition first qui placerait le poids (Weight) en tête, c'est la hauteur du corps (Height) qui se révèle la variable la plus discriminante, avec une importance de 0,3327, suivie par Length3, Width, Length1 et Length2, le poids arrivant en dernière position. Ce résultat est biologiquement cohérent : la hauteur relative du corps par rapport à sa longueur constitue un indicateur de silhouette (poisson trapu versus poisson fuselé) qui différencie naturellement des espèces comme le Brochet, au corps allongé et bas, d'espèces comme la Brème, au corps haut et comprimé.

Cette hiérarchie a une conséquence directe sur la lecture de la forte corrélation observée entre Length1, Length2 et Length3 (supérieure à 0,99). Bien que ces trois variables soient quasiment redondantes entre elles, leur importance cumulée reste significative, ce qui suggère que l'information qu'elles portent combinée à la hauteur est nécessaire à la discrimination. La redondance entre les trois longueurs ne semble donc pas pénaliser les modèles testés, probablement parce que les algorithmes utilisés (arbres, ensembles, marges) tolèrent relativement bien la multicolinéarité, contrairement à des modèles comme la régression logistique où elle peut déstabiliser l'estimation des coefficients.

3.4. Lecture des matrices de confusion

Les matrices de confusion confirment et précisent les résultats globaux. Le SVM ne commet quasiment aucune erreur, sa seule confusion concernant l'espèce Whitefish ce qui n'est pas surprenant étant donné qu'elle ne représente que 3,8 % du dataset (6 individus), et qu'avec

seulement 20 % de ces données en test, le modèle dispose d'un nombre d'exemples extrêmement limité pour apprendre les caractéristiques propres à cette classe.

Les trois autres modèles présentent davantage de confusions, notamment entre Perch, Roach et Smelt. Cette observation est cohérente avec l'analyse exploratoire : ces trois espèces partagent des gammes de poids et de dimensions relativement proches (poissons de taille petite à moyenne), ce qui rend leur séparation plus difficile pour des modèles moins aptes à exploiter finement les interactions entre variables. Le fait que ces confusions touchent systématiquement les mêmes espèces, quel que soit le modèle (hors SVM), indique qu'il s'agit moins d'une faiblesse propre à chaque algorithme que d'un chevauchement réel entre les distributions de ces espèces dans l'espace des variables disponibles.

3.5. Limites du travail réalisé

Plusieurs limites doivent être prises en compte dans l'interprétation de ces résultats :

- Taille réduite du dataset : avec seulement 159 observations, dont 32 dans le jeu de test, chaque erreur de classification représente plus de 3 points d'accuracy. Les écarts de performance entre modèles doivent donc être interprétés avec prudence, et pourraient varier sensiblement avec un autre découpage train/test.
- Déséquilibre des classes : la répartition inégale entre espèces (de 6 individus pour Whitefish à 56 pour Perch) favorise mécaniquement les espèces majoritaires dans le calcul de l'accuracy globale et complique l'apprentissage de représentations fiables pour les classes minoritaires.
- Multicolinéarité non traitée : la forte corrélation entre Length1, Length2 et Length3 n'a pas fait l'objet d'une réduction de dimensionnalité (par exemple via une ACP) ni d'une sélection de variables, ce qui aurait pu simplifier le modèle sans perte significative d'information.
- Absence de comparaison de noyaux pour le SVM : seul le noyau linéaire a été retenu comme meilleur, mais une analyse plus fine du comportement du noyau RBF face au noyau linéaire sur ce dataset précis aurait permis de mieux comprendre la nature de la frontière de décision.
- Origine et représentativité des données : le dataset provient vraisemblablement d'un échantillonnage ponctuel ; sa capacité à généraliser à des poissons issus d'autres populations, périodes ou conditions environnementales n'a pas été testée.

3.6. Synthèse de l'analyse critique

En définitive, les résultats obtenus démontrent qu'un modèle simple et bien régularisé ici un SVM linéaire associé à une normalisation rigoureuse des données peut surpasser des modèles

a priori plus sophistiqués comme le Random Forest sur un problème de classification dont la structure est majoritairement linéaire. Ce constat illustre un principe central en Machine Learning : la performance d'un modèle dépend moins de sa complexité intrinsèque que de son adéquation avec la géométrie réelle du problème posé. L'analyse de l'importance des variables, en mettant en avant le rôle de la hauteur du corps plutôt que du poids, apporte par ailleurs un éclairage biologique cohérent qui renforce la confiance accordée au modèle retenu, tout en ouvrant des pistes concrètes d'amélioration pour des travaux futurs.

CONCLUSION ET PERSPECTIVES

Ce projet avait pour objectif de concevoir un système de classification automatique des espèces de poissons à partir de mesures morphologiques simples, en s'appuyant sur le Fish Market Dataset. L'ensemble du pipeline de Machine Learning a été mis en œuvre avec rigueur : exploration des données, détection et traitement des valeurs atypiques, encodage de la variable cible, normalisation des variables numériques, séparation stratifiée des données, puis entraînement et optimisation de quatre algorithmes de classification supervisée.

Les résultats obtenus confirment la faisabilité de l'approche : le modèle SVM à noyau linéaire, optimisé avec $C = 100$ et $\gamma = \text{scale}$, atteint une accuracy de 96,88 % et un F1-score de 95,49 % sur le jeu de test, surpassant nettement le k-NN, l'Arbre de décision et le Random Forest, qui plafonnent tous à 81,25 %. Ce modèle a été retenu comme solution finale et sauvegardé, avec les objets de prétraitement associés (scaler et label encoder), afin d'être intégré dans une application Streamlit permettant une utilisation concrète et accessible du modèle.

Au-delà de la performance brute, ce projet a également permis de mieux comprendre la structure du problème : la forte importance de la hauteur du corps (Height) dans la distinction des espèces, la quasi-séparabilité linéaire des classes après normalisation, et les difficultés persistantes autour des espèces sous-représentées comme Whitefish. Ces enseignements dépassent le cadre du simple score et constituent une base solide pour orienter les améliorations futures.

Plusieurs pistes pourraient être explorées afin de consolider et d'enrichir les résultats obtenus :

- Collecte de données supplémentaires : augmenter le nombre d'observations, en particulier pour les espèces sous-représentées (Whitefish, Parkki, Smelt), afin de réduire le déséquilibre des classes et d'améliorer la robustesse de la validation croisée.
- Techniques de rééquilibrage : tester des méthodes telles que SMOTE ou un pondération des classes (`class_weight`) afin de limiter le biais en faveur des espèces majoritaires comme Perch et Bream.
- Réduction de dimensionnalité : appliquer une Analyse en Composantes Principales (ACP) pour traiter la forte corrélation entre Length1, Length2 et Length3, simplifier le modèle et visualiser la séparabilité des classes en deux ou trois dimensions.
- Exploration d'autres noyaux et modèles : comparer plus systématiquement le noyau RBF et le noyau polynomial pour le SVM, et tester des algorithmes additionnels tels que la Régression Logistique multinomiale, XGBoost ou LightGBM.

- Validation croisée renforcée : utiliser un nombre de folds plus élevé ou une validation croisée répétée (repeated k-fold) pour obtenir des estimations de performance plus stables, en particulier pour le k-NN dont l'écart-type CV est élevé.
- Amélioration de l'application Streamlit : enrichir l'interface avec des visualisations interactives (graphiques de probabilités, comparaison entre modèles), un historique des prédictions, et une vérification automatique de la cohérence des valeurs saisies par l'utilisateur.
- Déploiement en production : envisager une mise en ligne complète de l'application (hébergement cloud), accompagnée d'un suivi des performances du modèle dans le temps (monitoring) afin de détecter une éventuelle dérive si de nouvelles données sont intégrées.

En fin Ce projet a constitué une mise en application complète d'un pipeline de Machine Learning, depuis l'analyse exploratoire jusqu'au déploiement, sur un cas concret et interprétable. Il illustre la manière dont un problème de classification, en apparence simple, peut révéler des enseignements riches sur les données et sur le comportement des algorithmes, et ouvre la voie à de nombreuses pistes d'approfondissement pour des travaux futurs.

BIBLIOGRAPHIE

Datasets

1. Fish Market Dataset. Kaggle Repository.

Disponible sur : <https://www.kaggle.com/datasets/aungpyaeap/fish-market>

Ouvrages

2. Géron, A. (2022).

Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow (3rd Edition).

O'Reilly Media.

3. Hastie, T., Tibshirani, R., & Friedman, J. (2009).

The Elements of Statistical Learning: Data Mining, Inference, and Prediction (2nd Edition).

Springer.

4. Bishop, C. M. (2006).

Pattern Recognition and Machine Learning.

Springer.

5. James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021).

An Introduction to Statistical Learning with Applications in Python.

Springer.

Documentation technique

6. Scikit-Learn Developers.

Scikit-Learn Documentation.

Disponible sur : <https://scikit-learn.org>

7. Streamlit Team.

Streamlit Documentation.

Disponible sur : <https://docs.streamlit.io>

8. Joblib Documentation.

Disponible sur : <https://joblib.readthedocs.io>

9. Pandas Documentation.

Disponible sur : <https://pandas.pydata.org/docs>

10. NumPy Documentation.

Disponible sur : <https://numpy.org/doc>

11. Matplotlib Documentation.

Disponible sur : <https://matplotlib.org/stable>

12. Seaborn Documentation.

Disponible sur : <https://seaborn.pydata.org>